

1. (1%) 請說明這次使用的model架構，包含各層維度及連接方式。

wide_resnet50_2 是用採用 Bottleneck 來當model 基礎的 block，每一層會有兩層 Bottleneck 而當中第0個會執行 downsample。

Basic block:

Bottleneck:

```
conv1x1 - bn2d - conv3x3 - bn2d - conv1x1 - bn2d - relu-(conv2d - bn2d) (if  
downsampling)
```

Sequential(

```
(0): Conv2d(3, 64, kernel_size=(7, 7), stride=(2, 2), padding=(3, 3), bias=False)
```

```
(1): bn2d
```

```
(2): ReLU
```

```
(3): MaxPool2d(kernel_size=3, stride=2, padding=1, dilation=1, ceil_mode=False)
```

```
(4): (layer1): Sequential(3*Bottleneck)
```

```
in_planes = 64, out_planes = 256
```

```
(5): (layer2): Sequential(4*Bottleneck)
```

```
in_planes = 256, out_planes = 512
```

```
(6): (layer3): Sequential(6*Bottleneck)
```

```
in_planes = 512, out_planes = 1024
```

```
(7): (layer4): Sequential(3*Bottleneck)
```

```
in_planes = 1024, out_planes = 2048
```


```
(8): AdaptiveAvgPool2d(output_size=(1, 1))
```

)

flatten

```
Linear(in_features=2048, out_features=7, bias=True)
```


2. (1%) 請附上model的training/validation history (loss and accuracy)。



總共28888筆資料，這是把20000比當 training 剩下的8888筆當作 validation的結果，雖然在 validation set的準確率只有接近60%，但再把剩下的8888筆都加入 Training 以後，在kaggle 上的準確率卻突然升到 90%左右，猜測是這是suffle 出來的training set 和 validation set不平均所造成的。
[原來是training set 跟 kaggle test set 一樣的關係]

3. (1%) 畫出confusion matrix分析哪些類別的圖片容易使model搞混，並簡單說明。

(ref: https://en.wikipedia.org/wiki/Confusion_matrix)




在準確率的部分除了 Happy、Surprise 和 Neutral 以外都是低於50%的，除了對角線以外最高的數值是把 Disgust 判斷成 Angry 的 21% 和把 Neutral 判斷成 sad 21%，而資料中判斷最好的是 Happy 及 Surprise。


[關於第四及第五題]

可以使用簡單的 3-layer CNN model [64, 128, 512] 進行實作。

4. (1%) 畫出CNN model的saliency map，並簡單討論其現象。

(ref: <https://reurl.cc/Qpig8b>)





這是用3層CNN 跑出來的，可以發現gradient 比較大的地方在於鼻子跟嘴巴，還有這個人臉的輪廓，可以推斷說CNN 嘴巴的形狀對CNN影響最顯著，而這也跟這次 Sentiment classification 的目標相符合。

5. (1%) 畫出最後一層的filters最容易被哪些feature activate。
(ref: <https://reurl.cc/ZnrgYg>)



6. (3%) Refer to math problem

1. $(B, W, H, \text{input_channels})$

$\downarrow \text{Conv2D}(\text{input_channels}, \text{output_channels}, (k_1, k_2), (s_1, s_2), (P_1, P_2))$

$(B, \lfloor \frac{W+2P_1-k_1+1}{s_1} \rfloor + 1, \lfloor \frac{H+2P_2-k_2+1}{s_2} \rfloor + 1, \text{output_channels})$

2. $\frac{\partial l}{\partial x_i} = \frac{\partial l}{\partial z_i} \cdot \gamma$

$\frac{\partial l}{\partial \sigma_B^2} = \sum_{i=1}^m \frac{\partial l}{\partial x_i} \cdot (x_i - \mu_B) \cdot \frac{-1}{2} (\sigma_B^2 + \epsilon)^{-3/2}$

$\frac{\partial l}{\partial \mu_B} = \left(\sum_{i=1}^m \frac{\partial l}{\partial x_i} \cdot \frac{-1}{\sqrt{\sigma_B^2 + \epsilon}} \right) + \frac{\partial l}{\partial \sigma_B^2} \cdot \frac{\sum_{i=1}^m -2(x_i - \mu_B)}{m}$

$\frac{\partial l}{\partial x_i} = \frac{\partial l}{\partial z_i} \cdot \frac{1}{\sqrt{\sigma_B^2 + \epsilon}} + \frac{\partial l}{\partial \sigma_B^2} \cdot \frac{2(x_i - \mu_B)}{m} + \frac{\partial l}{\partial \mu_B} \cdot \frac{1}{m}$

$\frac{\partial l}{\partial \sigma} = \sum_{i=1}^m \frac{\partial l}{\partial x_i} \cdot \hat{x}_i$

$\frac{\partial l}{\partial \beta} = \sum_{i=1}^m \frac{\partial l}{\partial x_i}$

3. $\frac{\partial L_x}{\partial z_x} = \frac{\partial}{\partial z_x} -y_x \log \frac{e^{z_x}}{\sum e^{z_i}} = -y_x \left(1 - \frac{\partial}{\partial z_x} \log \sum e^{z_i} \right)$

$= -y_x \left(1 - \frac{e^{z_x}}{\sum e^{z_i}} \right) = -y_x (1 - \hat{y}_x)$

$= y_x \hat{y}_x - y_x$

$= \hat{y}_x - y_x, (y_x = 1)$

